

Timothée Poisot

Introduction à **R** Par la pratique

UQAR — Mai 2012

Table des matières

Table des matières	iii
1 Introduction	1
1.1 Environnement de travail	1
1.2 Types de données	1
2 Lecture et écriture des données	9
2.1 Lecture depuis des fichiers textes	9
3 Opérations sur les tables de données	11
3.1 Travail sur les lignes et colonnes	11
3.2 Traitement des données	11
3.3 Division et traitement par niveau	11
4 Introduction à la programmation	13
4.1 Programmer, pourquoi ?	13
4.2 Boucles	13
4.3 Tests	15
4.4 Fonctions	17
4.5 Mise en application	20
4.6 Solution des mises en application	21
5 Graphiques	23
5.1 Quelques généralités sur les graphiques	23
5.2 Principaux types de visualisations	23
5.3 Ajout d'éléments sur un graphique	25
5.4 Enregistrement des figures	25
5.5 Mise en application	25
5.6 Solution des mises en application	26
Introduction au calcul parallèle	29
Bibliographie	31

1 Introduction

L'objectif de ce cours est de fournir une introduction générale à R [R-Development-Core-Team2008], un langage qui est en train de devenir un standard en analyse de données et calcul scientifique. R est souvent présenté dans l'optique d'une utilisation pour les statistiques. Si c'est effectivement une des capacités les plus souvent utilisées de ce langage, ce cours n'abordera pas ce domaine. L'objectif des 6 séances est de fournir, au travers d'exemples et de mises en application, un aperçu suffisamment vaste de R pour le rendre utilisable dans la plus grande majorité des situations : nous aborderons donc les bases du langage, en commençant par les types d'objets utilisés par R, puis consacrerons une partie importante du temps à lire, écrire, et manipuler des jeux de données. Les dernières séances sont consacrées à la programmation et aux graphiques, qui permettront d'aller plus loin par la suite.

1.1 Environnement de travail

La première étape est de mettre en place notre environnement de travail. Si ce n'est pas déjà fait, commencez par installer R, disponible à <http://www.r-project.org/>.

RStudio est un environnement intégré de travail pour R gratuit, multi-plateforme, disponible en ligne à <http://rstudio.org/>. La première partie de la séance sera consacrée à l'utilisation de RStudio.

1.2 Types de données

Types de valeurs

Numériques

Chaînes

Booléens

Collections de valeurs

Vecteurs et vectorisation

Le vecteur est, avec la matrice, l'objet le plus important de R. R est un langage dit *vectorisé*, c'est-à-dire qui peut traiter plusieurs valeurs regroupées dans un objet unique. Si on utilise une commande très simple, comme

2

```
## [1] 2
```

on remarque que la sortie est `[1] 2`. L'indicateur `[1]` indique que la valeur retournée est le premier élément d'un vecteur. La puissance de la notation vectorielle est qu'on peut accéder à une partie du vecteur, avec un *indice*. Si on prend l'exemple suivant,

```
a <- 2
a[1]

## [1] 2

a[2]

## [1] NA
```

, accéder à la position 1 *via* l'*indice* `[1]`, on récupère la première valeur du vecteur `a`. Voilà une des particularités de R : tout objet est un vecteur ! Accéder à la position `[2]` retourne `NA`, parce que le vecteur `a` ne possède pas de deuxième position.

On peut créer des vecteurs dans R en utilisant la commande `c`.

```
vecteur <- c(1, 2, 3, 4, 5)
```

R propose différents raccourcis pour créer rapidement des vecteurs. Par exemple, examinez le comportement des commandes suivantes :

```
seq(from = 0, to = 5, by = 1)

## [1] 0 1 2 3 4 5

seq(from = 0, to = 10, length = 3)

## [1] 0 5 10

c(0:5)

## [1] 0 1 2 3 4 5
```

L'avantage de la vectorisation est que R va automatiser une grande partie des opérations sur les vecteurs. Par exemple, examinez l'effet des commandes suivantes :

```
a <- c(1:10)
a/2

## [1] 0.5 1.0 1.5 2.0 2.5 3.0 3.5 4.0 4.5 5.0

log(a, 10)

## [1] 0.0000 0.3010 0.4771 0.6021 0.6990 0.7782 0.8451 0.9031 0.9542 1.0000

a * a

## [1] 1 4 9 16 25 36 49 64 81 100
```

Avec les vecteurs vient le concept important de *recyclage*. Le recyclage consiste à répéter un vecteur autant de fois que nécessaire pour le rendre compatible avec un autre vecteur dans le cadre d'une opération. Par exemple, les commandes

```
c(1, 2, 3, 4, 5) + c(1, 2)
```

```
## [1] 2 4 4 6 6
```

et

```
c(1, 2, 3, 4, 5) + c(1, 2, 1, 2, 1)
```

```
## [1] 2 4 4 6 6
```

sont équivalentes. Le vecteur `c(1, 2)` du premier exemple est *recyclé* pour atteindre la longueur du premier vecteur.

La taille d'un vecteur est obtenue en utilisant la fonction `length` :

```
length(1)
```

```
## [1] 1
```

```
length(c(1:5))
```

```
## [1] 5
```

todo Créer des vecteurs null

Matrices

Le type matrice est central dans le fonctionnement de R. Une fois le principe des vecteurs compris, le fonctionnement des matrices est assez intuitif. Une matrice est en fait un vecteur à deux dimensions. Si un vecteur est une ligne, une matrice est une série de lignes et de colonnes. Dans R, on peut créer une matrice avec la commande `matrix`, de sorte que

```
test_mat <- matrix(0, ncol = 2, nrow = 4)
```

renvoie une matrice pleine de 0, avec 2 colonnes (`ncol`) et 4 lignes (`nrow`).

On peut connaître les dimensions d'une matrice de différentes manières :

```
dim(test_mat)
```

```
## [1] 4 2
```

```
nrow(test_mat)
```

```
## [1] 4
```

```
ncol(test_mat)
```

```
## [1] 2
```

Accéder à une position particulière d'une matrice se fait en deux temps. D'abord, par le numéro de la ligne, ensuite par le numéro de la colonne. Par exemple, on peut fixer l'élément sur la première ligne, deuxième colonne de `test_mat` à 2, avec

```
test_mat[1, 2] <- 2
test_mat
```

```
##      [,1] [,2]
## [1,]    0    2
## [2,]    0    0
## [3,]    0    0
## [4,]    0    0
```

Dans certaines situations, on peut souhaiter avoir accès à une ligne ou une colonne en particulier. R permet donc de ne spécifier qu'un numéro de ligne, ou un numéro de colonne :

```
test_mat[, 2]
```

```
## [1] 2 0 0 0
```

```
test_mat[1, ]
```

```
## [1] 0 2
```

Une matrice peut aussi posséder des noms de lignes et de colonnes :

```
colnames(test_mat) <- c("a", "b")
rownames(test_mat) <- c("A", "B", "C", "D")
test_mat
```

```
##   a b
## A 0 2
## B 0 0
## C 0 0
## D 0 0
```

```
colnames(test_mat)
```

```
## [1] "a" "b"
```

Cela permet aussi d'accéder plus facilement à certaines positions de la matrice :


```
test_mat["A", ]  
  
## a b  
## 0 2  
  
test_mat["A", "b"]  
  
## [1] 2
```

Listes

Un des derniers types d'objets qu'il faut connaître est les listes. Une liste, dans R, est une manière de stocker de l'information venant de source diverses, pour y accéder facilement. On verra dans la séance 3 que les listes permettent aussi de traiter très rapidement plusieurs jeux de données à la suite.

Pour créer une liste, on peut utiliser différentes méthodes :

```
n_list <- list(a = 1, b = 2, c = 3)  
n_list  
  
## $a  
## [1] 1  
##  
## $b  
## [1] 2  
##  
## $c  
## [1] 3  
##  
  
u_list <- list(1, 2, 3)  
u_list  
  
## [[1]]  
## [1] 1  
##  
## [[2]]  
## [1] 2  
##  
## [[3]]  
## [1] 3  
##
```

Les listes, comme `n_list`, peuvent être nommées :

```
names(n_list)
```

```
## [1] "a" "b" "c"
```

On peut accéder aux éléments des listes de différentes manières. Si la liste est nommée, la notation `liste$nom` est possible ; dans tous les autres cas, `liste[[indice]]` fonctionne.

```
n_list$a
```

```
## [1] 1
```

```
n_list[[1]]
```

```
## [1] 1
```

Les listes peuvent être utilisées dans le contexte de la structure `with`, qui permet d'accéder facilement aux différents éléments. Pour simplifier, `with` permet d'éviter d'écrire `liste$nom` pour écrire `nom` ; les deux commandes ci-dessous sont donc équivalentes :

```
n_list$a + n_list$b - n_list$c
```

```
## [1] 0
```

```
with(n_list, {
  a + b - c
})
```

```
## [1] 0
```

Dans certains cas, il peut être intéressant d'aplatir une liste en un vecteur. R propose la fonction `unlist` pour effectuer cette opération :

```
t_list <- list(1, 2, 3, 4, 5, 6)
t_list
```

```
## [[1]]
```

```
## [1] 1
```

```
##
```

```
## [[2]]
```

```
## [1] 2
```

```
##
```

```
## [[3]]
```

```
## [1] 3
```

```
##
```

```
## [[4]]
```

```
## [1] 4
```

```
##  
## [[5]]  
## [1] 5  
##  
## [[6]]  
## [1] 6  
##  
  
unlist(t_list)  
  
## [1] 1 2 3 4 5 6
```

Data frames

Vu plus en détail dans les autres séances.

2 Lecture et écriture des données

R propose plusieurs manières de lire des données, depuis des fichiers textes ou des tableaux Excel. L'objectif de cette séance est de lire, et mettre en forme des données. Nous aborderons aussi les moyens de sauvegarder ces données sur le disque. Pour la durée de la séance, on suppose que l'ensemble des données qu'on veut lire sont stockées dans le répertoire `./data/`.

2.1 Lecture depuis des fichiers textes

La méthode la plus simple de stocker des fichiers texte, et la seule recommandée si on veut s'assurer de pouvoir lire les données partout, en tout temps, est d'utiliser des fichiers texte.

Dans cet exemple, on utilisera les données prises par POISOT et DESDEVISES [1] sur 147 parasites du genre *Lamellodiscus*, parasites de poissons communs en Méditerranée. Ces données correspondent aux relevés morphométriques effectuées sur les parties solides de l'appareil d'attachement. Les données sont classées selon l'espèce du parasite (sppar), et l'espèce de l'hôte sur lequel le parasite a été isolé (sphote).

```
morpho <- read.table("data/lamellodiscus.txt", h = TRUE, sep = "\t")
head(morpho)
```

```
##   sphote sppar   para    a    b    c    d    f    g    aa    bb    cc    lm
## 1   Divu  eleg elegDivu1 2.06 1.93  NA  NA  NA  NA 1.93 1.81 1.16 5.43
## 2   Divu  eleg elegDivu2 1.93 1.82 1.51 0.41 0.57 0.20 1.77 1.67 1.20 2.35
## 3   Divu  eleg elegDivu2 1.67 1.56 1.20 0.31 0.36 0.26 1.56 1.51 0.94 1.88
## 4   Disa  eleg elegDisa1 1.46 1.41 1.04 0.47 0.67 0.31 1.25 1.20 0.83 1.46
## 5   Disa  eleg elegDisa1 1.30 1.25 0.94 0.36 0.52 0.31 1.14 1.09 0.78  NA
## 6   Disa  eleg elegDisa1 1.41 1.35 0.99 0.36 0.57 0.36 1.25 1.20 0.83 2.08
##    li
## 1 2.66
## 2 2.66
## 3 1.77
## 4 2.19
## 5 2.03
## 6 2.55
```


3 Opérations sur les tables de données

3.1 Travail sur les lignes et colonnes

Dans une grande variété de situations, il peut être avantageux de répéter une opération sur toutes les lignes, ou toutes les colonnes. R propose une fonction pour automatiser ce traitement, *via* la fonction `apply`.

```
dat <- matrix(rnorm(100), nrow = 10)
apply(dat, 1, mean)

## [1] 0.3636 -0.1601 -0.1409 0.2279 0.7192 0.2508 0.3597 0.4507
## [9] -0.2436 0.4394

apply(dat, 2, var)

## [1] 0.6659 1.6678 0.7538 1.0510 0.4947 0.6434 1.2381 1.8382 1.2181 2.1166
```

3.2 Traitement des données

3.3 Division et traitement par niveau

En utilisant différentes fonctions, on peut traiter facilement un jeu de données par «niveaux» d'un facteur (p.ex. traitement expérimental). En rechargeant les données *Lamellodiscus*, on peut par exemple chercher à connaître la moyenne et la variance de la taille de chaque pièce sclérifiée.

```
morpho <- read.table("data/lamellodiscus.txt", h = TRUE, sep = "\t")
```


4 Introduction à la programmation

4.1 Programmer, pourquoi ?

Dans les séances précédentes, nous avons utilisé des fichiers `.R` pour sauvegarder des listes d'instructions. Nous avons aussi chargé et manipulé des jeux de données. Il est souvent nécessaire d'automatiser tout ou partie de ce processus, ce qui implique de faire appel à de la programmation.

L'objectif de cette séance est de

4.2 Boucles

Les boucles permettent parcourir une liste, ou de répéter une série d'instructions, dans des conditions bien définies ; c'est une des structures de base de l'algorithmique. R propose deux types de boucles, les boucles `for` et les boucles `while`. En français, on peut les résumer par «pour chaque» et «tant que».

Boucles de type *for*

Une boucle `for` permet de répéter un bloc d'instructions un nombre prédéfini de fois, ou d'exécuter des commandes pour chaque élément d'un tableau de données. La syntaxe de base est la suivante :

```
for (step in c(1:10)) cat(step)
```

```
## 12345678910
```

En clair, pour chaque valeur entre 1 et 10, qu'on nomme `step` (mais qu'on aurait pu nommer n'importe comment), on affiche (`cat`) la valeur de `step`. On peut bien sûr spécifier plusieurs instructions qui doivent être exécutées à chaque *itération* (étapes de la boucle) en utilisant les accolades :

```
for (step in c(1:3)) {  
  cat(step)  
  print(summary(rnorm(100, mean = step)))  
}
```

```
## 1  Min. 1st Qu.  Median    Mean 3rd Qu.    Max.  
## -1.200  0.397  1.050   1.070   1.620   3.740  
## 2  Min. 1st Qu.  Median    Mean 3rd Qu.    Max.  
## -0.306  1.260  1.780   1.940   2.500   4.640  
## 3  Min. 1st Qu.  Median    Mean 3rd Qu.    Max.  
##  0.784  2.340  3.140   3.120   3.880   5.280
```

Cette commande affiche le numéro de l'itération en cours (`cat(step)`), puis affiche les informations de base (`summary`) sur une distribution normale (`rnorm`) centrée sur `step`. Les boucles `for` peuvent contenir des instructions aussi longues que souhaité.

Une autre application des boucles `for` est de parcourir un objet. Par exemple, on peut souhaiter, pour chaque élément d'un objet, afficher sa valeur. R permet de réaliser ce genre d'opérations, avec la syntaxe suivante :

```
vect <- c("a", "b", "c", "d")
for (val in vect) cat(val)

## abcd
```

Pour chaque élément du vecteur `vect`, que l'on nomme `val` pour pouvoir y accéder pendant les itérations, R va afficher la valeur que l'élément contient.

Les boucles `for` sont donc une façon explicite de faire la même chose que ce qui a été traité dans la séance précédente, avec un inconvénient majeur : elles sont extrêmement demandantes en temps de calcul. Dans la majorité des cas, il est préférable d'avoir recours autant que possible aux fonctions `*apply`, qui sont bien plus optimisées que des boucles.

Boucles de type *while*

Les boucles de type `while`, littéralement *pendant*, permettent de répéter une série d'instructions tant qu'une condition n'a pas été atteinte. Pour cette raison, il faut bien prendre en compte le fait que mal utilisées, ces boucles peuvent ne jamais stopper. Il faut donc faire particulièrement attention à la condition qui est évaluée à chaque itération.

Un exemple simple d'utilisation d'une boucle `while` est le calcul d'une factorielle. On veut calculer $n!$, ce qui se fait simplement en multipliant l'ensemble des $1 \leq k \leq n$.

```
n <- 5
k <- n
while (k > 1) {
  k <- k - 1
  n <- n * k
}
print(n)

## [1] 120
```

On remarquera que dans la parenthèse après `while` se trouve un test logique ; les tests sont abordés dans la partie suivante.

Sortir d'une boucle et sauter des étapes

Lors de l'exécution d'une boucle, on peut ne pas vouloir exécuter toutes les instructions. R possède des structures de contrôle pour effectuer ce type d'opérations. Les principales qu'il faut connaître sont `break` et `next`. L'instruction `break` permet de stopper l'exécution de la boucle, c'est-à-dire de sortir de la boucle comme si la condition de sortie était remplie, ou le nombre maximal d'itérations atteint. La boucle suivante va afficher les valeurs de `i` tant qu'elles sont inférieures à 3, et afficher `bye` ! puis stopper la boucle sinon.

```
for (i in c(1:5)) {  
  if (i < 3) {  
    cat(i)  
  } else {  
    cat(" bye!")  
    break  
  }  
}  
  
## 12 bye!
```

Une autre structure de contrôle intéressant est `next`, qui permet de sauter une itération si la valeur de l'itérateur ne nous plaît pas. Cette structure est particulièrement utile quand on réalise un nombre important d'opérations à chaque itération, et qu'on ne veut pas perdre de temps à traiter des valeurs qui ne nous intéressent pas. On peut utiliser `next` pour avoir, par exemple, une liste de tous les nombres pairs entre 1 et 10 :

```
is.even <- function(x) x%%2 == 0  
for (i in c(1:10)) {  
  if (is.even(i)) {  
    cat(i)  
    cat(" is even\n")  
  } else {  
    next  
  }  
}  
  
## 2 is even  
## 4 is even  
## 6 is even  
## 8 is even  
## 10 is even
```

4.3 Tests

Cette partie est consacrée à l'utilisation des tests. On a vu dans les séances précédentes l'existence de variables de type booléen, qui prennent les valeurs `TRUE` ou `FALSE`. Des variables de ce type sont utilisées dans le cadre d'expressions conditionnelles, c'est-à-dire quand on souhaite effectuer différentes instructions en fonction de la valeur d'une condition.

Expressions conditionnelles

La structure de base d'une expression conditionnelle est la suivante :

Opérateur	Signification	Version 1	Version 2
\vee	ou (au moins une des deux)	or	,
\wedge	et (les deux)	and	&, &&
\neg	non	not	!
\oplus	ou conditionnel (seulement une des deux)	xor(a, b)	
\in	est compris dans	%in%	
=	égalité		==
\leq	inférieur ou égal		<=
\geq	supérieur ou égal		>=
>	supérieur		>
<	inférieur		<

TABLE 4.1: Différents opérateurs logiques disponibles dans R.

```
if (condition) {
  instruction(1)
} else {
  instruction(2)
}
```

Une notation comme

```
if (condition) instruction
```

est aussi acceptable, de même que

```
val <- ifelse(condition, valeur_if, valeur_else)
```

Cette dernière notation permet de gagner du temps quand on veut que la valeur d'une variable dépende d'une condition. Par exemple, $(n \geq 2) \vee (n = 0)$ s'écrit $(n \leq 2) \text{ or } (n == 0)$, ou encore $(n \leq 2) | (n == 0)$. Les différents opérateurs logiques sont regroupés dans le tableau 4.1.

L'argument `condition` prend la forme d'un test logique, qui peut être d'une complexité aussi grande que l'on veut. Pour certains des opérateurs, il existe deux variantes (`|` et `||`, `&` et `&&`). On peut comprendre pourquoi avec les exemples suivants :

```
a <- c(1, 2, 3, 4, 5, 6)
b <- c(1, 2, 3, 4, 4, 6)
d <- c(3, 2, 3, 4, 5, 4)
(a == b)

## [1] TRUE TRUE TRUE TRUE FALSE TRUE

(a == d)
```

```
## [1] FALSE TRUE TRUE TRUE TRUE FALSE
```

```
(b == d)
```

```
## [1] FALSE TRUE TRUE TRUE FALSE FALSE
```

```
(a == d) & (a == b)
```

```
## [1] FALSE TRUE TRUE TRUE FALSE FALSE
```

```
(a == d) && (a == b)
```

```
## [1] FALSE
```

```
(a == d) | (a == b)
```

```
## [1] TRUE TRUE TRUE TRUE TRUE TRUE
```

```
(a == d) || (a == b)
```

```
## [1] TRUE
```

L'opérateur répété une seule fois est *elemt-wise* : les éléments des vecteurs sont comparés deux à deux (et on applique du recyclage). L'opérateur répété deux fois

Manipulation des valeurs booléennes

addition, multiplication, ...

4.4 Fonctions

Généralités

L'utilisation des fonctions va permettre de gagner du temps dans la programmation. Comprendre le principe des fonctions dépasse de beaucoup le cadre de R, et mérite qu'on s'y arrête. Qu'est-ce qu'une fonction ? Une série d'instructions qui vont, à partir d'arguments, renvoyer un résultat. En quoi est-ce différent des scripts que nous avons utilisé jusqu'ici ? Écrire une fonction revient en quelque sorte à 'expliquer' le code une fois, et R se charge ensuite de redonner la bonne valeur aux arguments.

Le parallèle le plus évident est celui des fonctions mathématiques : si $f(x) = x^2$, on peut calculer $f(x)$ pour tout x , parce qu'on sait quoi faire. Ça devient donc très avantageux si on doit calculer $f(x)$ un grand nombre de fois. En écrivant uniquement des scripts, pour calculer la valeur de beaucoup de x^2 , on aurait écrit :

```
1^2
```

```
2^2
```

```
3^2
```

```
4^2
```

```
5^2
```

ou encore

```
for (i in c(1:5)) i^2
```

Si il faut revenir sur ce code plus tard, et transformer tous les 2 en 3 , la première solution implique de tout corriger manuellement. En utilisant une fonction, la logique est différente :

```
f <- function(x) x^2
f(2)

## [1] 4
```

Peut importe le nombre de fois ou on devra effectuer l'opération contenue dans `f`, si on veut la modifier, elle sera toujours stockée au même endroit. Avec cet avantage en tête, quelques généralités sur les fonctions en R.

Tout est fonction

Dans la pratique, la majorité des instructions utilisées jusqu'à présent sont des fonctions. Par exemple, `print`, `read.table`, et `apply` sont des fonctions rendues disponibles par R.

Le *scope*

Les fonctions existent comme un espace «à part» dans R : ce qui se déroule dans une fonction, reste dans une fonction. Prenons le cas du code suivant :

```
a <- 2
b <- 3
f <- function(x) {
  y <- x + a
  z <- y
  return(z)
}
f(b)

## [1] 5
```

La fonction `f` peut aller chercher la valeur de `a` dans l'environnement global, mais tout ce qui est défini au sein de `f` est inaccessible. D'ailleurs, tout ce qui est créé dans la fonction est détruit – retiré de la mémoire – une fois que la dernière instruction est exécutée. Voyez la section sur la fonction `return` pour plus de détails. Cette notion de quel objet est accessible est extrêmement importante à maîtriser.

Dans R, les objets existent dans deux «mondes», l'environnement global, et l'intérieur de chaque fonction. L'intérieur de chaque fonction peut avoir accès aux objets et aux variables de l'environnement global, même si cette pratique est à éviter pour différentes raisons (une variable globale peut être modifiée entre deux appels à la fonction, notamment). En revanche, l'environnement global n'a pas accès aux objets créés ou modifiés à l'intérieur d'une fonction. La communication avec les fonctions se fait ...

Le fait qu'on puisse passer des objets d'un environnement à l'autre peut entraîner un comportement assez surprenant. Dans l'exemple suivant :

```
a <- 2
print(a)

## [1] 2

f <- function(a) {
  a <- a + 1
  return(a)
}
print(f(a))

## [1] 3

print(a)

## [1] 2
```

l'appel à la fonction `f` devrait modifier `a`, puisque la seule instruction de cette fonction est `a = a+1`. Or, quand on appelle cette fonction, puis qu'on affiche la valeur de `a`, elle n'a pas changé. Ce comportement vient du fait que l'objet `a` qui existe dans la fonction n'est pas celui qui existe dans l'environnement global. Par conséquent, le `a` de la fonction peut être modifié, sans que cela n'affecte le `a` de l'environnement de travail.

Cet exemple illustre aussi pourquoi le nom des variables est important. On sait que R est capable d'aller chercher, depuis une fonction, des variables de l'environnement global. Quelle version de `a` faut-il aller chercher ? Pour éviter les erreurs liées au fait que plusieurs variables aient le même nom, on essaie de donner un nom unique à toutes les variables. C'est sans doute plus long à écrire – même si cet argument n'est pas valable avec un éditeur qui auto-complète le code –, mais ça évite surtout les erreurs à l'exécution.

Déclarer une fonction

Comme illustré dans les exemples précédents, la déclaration d'une fonction se fait par

```
nom_de_la_fonction <- function(argument1, argument2) {
  instructions
  return(sortie)
}
```

Les éléments les plus importants sont les arguments et l'instruction `return`.

La commande *return*

Arguments

Les arguments sont des variables

4.5 Mise en application

Test par permutation

Lorsque les données ne suivent pas la normalité, on peut préférer réaliser un test paramétrétique avec des permutations plutôt qu'un test non paramétrique. La plupart des programmes de statistique n'offrent pas cette possibilité qui demande pourtant très peu d'efforts pour être implémentée dans R. Dans cette mise en application, on veut effectuer un test t , pour comparer deux distributions, disponibles dans un fichier `s4-data.txt`.

Le principe d'un test par permutations est simple. La première étape est d'effectuer le test sur l'échantillon non permuté, pour obtenir la valeur de la statistique (T). Dans le cas du test t , R propose la fonction `t.test`, et un rapide survol de `?t.test` vous donnera les arguments nécessaires et la manière de récupérer la statistique. Commencent ensuite les permutations à proprement parler. Pour un nombre n d'itérations choisies (en général 9999), on mélange l'ensemble des valeurs des deux distributions. On reconstruit ensuite, en tirant au hasard dans le *pool* de valeurs ainsi formées, deux distributions de taille égale. Cette étape peut, par exemple, prendre la forme d'une fonction `resample`, qui prendrait une `data.frame` avec deux colonnes (la valeur, et le groupe d'origine) en argument. R propose la fonction `sample`, qui permettra de mélanger la colonne correspondant au groupe (ce qui recréera automatiquement les deux distributions – économisons nous !). Une fois les deux distributions reconstruites, on calcule la nouvelle statistique T' . Si la valeur de T' est inférieure ou égale à la valeur de T , on incrémente une variable N de 1. Sinon, la valeur de N reste la même.

Le calcul de la *p-value* se fait de la manière suivante :

$$p = \frac{N}{n + 1} \quad (4.1)$$

À partir de ces informations, et des informations données dans l'introduction de cette séance, vous devez être en mesure de programmer sans difficultés une fonction `t.test.permut`, qui permet de réaliser un test t par permutations. En bonus, vous pouvez ajouter des arguments qui permettent de contrôler le nombre de permutations qui doivent être réalisées.

4.6 Solution des mises en application

Test par permutation

On commence par écrire une fonction `resample`, qui mélange l'attribution des valeurs à un des deux groupes.

```
resample <- function(df) {
  df$group <- sample(df$group)
  return(df)
}
```

Puis on écrit la fonction `t.test.permut`, qui effectue les permutations à proprement parler

```
t.test.permut <- function(df, n = 9999) {
  baseStat <- t.test(value ~ group, df)$statistic
  N <- 0
  for (repl in c(1:n)) if (t.test(value ~ group, resample(df))$statistic <=
    baseStat)
    N <- N + 1
  return(N/(n + 1))
}
```

On peut générer un jeu de données de test :

```
value <- c(rnorm(100, mean = 0), rnorm(100, mean = 1))
group <- c(rep("a", 100), rep("b", 100))
test_df <- as.data.frame(cbind(value = value, group = group))
test_df$value <- as.numeric(as.vector(test_df$value))
```

puis vérifier que la *p-value* est inférieure à 0.05 :

```
print(t.test.permut(test_df, n = 9))

## [1] 0
```

Pour éviter les problèmes de lenteur des boucles `for`, on peut écrire la même fonction basée sur la fonction `replicate` :

```
t.test.permut <- function(df, n = 9999) {
  baseStat <- t.test(value ~ group, df)$statistic
  return(sum(replicate(n, t.test(value ~ group, resample(df))$statistic <=
    baseStat))/(n + 1))
}
```

La différence sur 10000 réplicats est assez minime (3 secondes environ). Mais dans un contexte où il faut analyser plusieurs fois des jeux de données, ces petits écarts finissent par faire une différence importante.

5 Graphiques


5.1 Quelques généralités sur les graphiques

5.2 Principaux types de visualisations

Nuages de points

La manière la plus simple de représenter un objet dans R est d'utiliser la fonction `plot`. Par exemple,

```
dat <- sort(rnorm(100))  
plot(dat)
```




R va prendre en charge le calcul d'une grande partie des paramètres nécessaires à la visualisation, comme par exemple les limites des différents axes, et l'espacement entre les valeurs sur les axes. Il est possible de manuellement spécifier l'ensemble de ces paramètres. Par exemple, on peut vouloir changer les étiquettes des axes x et y par quelque chose de plus explicite.

Histogrammes


R offre la possibilité de représenter facilement des distributions, *via* des commandes particulières. La plus simple d'utilisation est `hist`, qui permet de représenter un histogramme.

```
distrib <- rnorm(1000)  
hist(distrib)
```




Par défaut, R attribue un titre à ces graphiques ; on peut supprimer ce titre en mettant l'argument `main` à une valeur nulle.

```
hist(distrib, main = "")
```



On peut choisir la couleur des barres, *via* l'argument `col`. Comme dans un grand nombre de situations dans lesquelles on fait appel à des vecteurs, R utilise le recyclage : si le nombre de barres de l'histogramme est plus grand que le nombre de couleurs fournies, les couleurs des barres sont alternées.

```
hist(distrib, main = "", col = c(1, 2, 3))
```



Boxplots

5.3 Ajout d'éléments sur un graphique

Autres séries de données

Légendes et axes

Annotations

5.4 Enregistrement des figures

5.5 Mise en application

Diagramme en barres

Colorer les barres au dessus et au dessous d'une certaine valeur.

5.6 Solution des mises en application

Diagramme en barres

On souhaite représenter une diagramme en barres, et colorer les barres qui sont au dessous ou au dessus de valeurs données. On commence par choisir la série de données qui nous intéresse – on peut la trier en ordre croissant, pour faciliter la lecture du graphique :

```
test_data <- c(1, 4, 3, 12, -2, -6, -1, 1)
test_data <- sort(test_data)
```

Pour colorer chaque barre de manière indépendante, on va créer un vecteur `colors`, qui contiendra une valeur par barre :

```
colors <- rep(2, length(test_data))
```

Chaque barre sera donc de la couleur 2, qui dépend de la palette actuelle. Pour changer la couleur de chaque barre, il y a deux approches. La première consiste à écrire une boucle :

```
for (co_idx in c(1:length(test_data))) {
  if (test_data[co_idx] > 10)
    colors[co_idx] <- 3
  if (test_data[co_idx] < -5)
    colors[co_idx] <- 1
}
```


Une méthode plus élégante tire parti de la vectorisation :

```
colors[test_data > 10] <- 3
colors[test_data < -5] <- 1
colors
```

```
## [1] 1 2 2 2 2 2 2 3
```

On peut ensuite afficher le graphique avec les barres de chaque couleur :

```
barplot(test_data, col = colors, ylim = range(test_data) + c(-2,
  2), space = 0)
abline(h = 0, lwd = 2)
box()
```



Introduction au calcul parallèle

L'objectif de ce chapitre est de fournir des «recettes» sur le calcul parallèle, en utilisant les librairies `snow` et `snowfall`.

Bibliographie

- [1] T. POISOT et Y. DESDEVISES. “Putative speciation events in *Lamellodiscus* (Monogenea: Diplectanidae) assessed by a morphometric approach”. Dans : *Biological Journal of the Linnean Society* 99.3 (fév. 2010), p. 559–569.