

Introduction à la programmation

Timothée Poisot

Résumé

L'objectif de cette séance est l'initiation à la programmation. Les principales structures d'algorithmes et les opérateurs logiques seront abordés.

Table des matières

1	Programmer, pourquoi ?	1
2	Boucles	2
2.1	Boucles de type <i>for</i>	2
2.2	Boucles de type <i>while</i>	3
3	Tests	3
3.1	Expressions conditionnelles	3
3.2	Manipulation des valeurs booléennes	4
4	Fonctions	4
4.1	Généralités	4
4.1.1	Tout est fonction	4
4.1.2	Le <i>scope</i>	5
4.2	Déclarer une fonction	6
4.2.1	La commande <i>return</i>	6
4.2.2	Arguments	6
5	Mise en application	6
5.1	Test par permutation	6
6	Solution des mises en application	8
6.1	Test par permutation	8

1 Programmer, pourquoi ?

Dans les séances précédentes, nous avons utilisé des fichiers `.R` pour sauvegarder des listes d'instructions. Nous avons aussi chargé et manipulé des jeux de données. Il est souvent nécessaire d'automatiser tout ou partie de ce processus, ce qui implique de faire appel à de la programmation.

L'objectif de cette séance est de

2 Boucles

Les boucles permettent parcourir une liste, ou de répéter une série d'instructions, dans des conditions bien définies ; c'est une des structures de base de l'algorithmique. R propose deux types de boucles, les boucles `for` et les boucles `while`. En français, on peut les résumer par «pour chaque» et «tant que».

2.1 Boucles de type *for*

Une boucle `for` permet de répéter un bloc d'instructions un nombre prédéfini de fois, ou d'exécuter des commandes pour chaque élément d'un tableau de données. La syntaxe de base est la suivante :

```
> for (step in c(1:10)) cat(step)
```

```
12345678910
```

En clair, pour chaque valeur entre 1 et 10, qu'on nomme `step` (mais qu'on aurait pu nommer n'importe comment), on affiche (`cat`) la valeur de `step`. On peut bien sûr spécifier plusieurs instructions qui doivent être exécutées à chaque *itération* (étapes de la boucle) en utilisant les accolades :

```
> for (step in c(1:3))
{
    cat(step)
    print(summary(rnorm(100,mean=step)))
}
```

```
1  Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
-1.0720 0.4238 0.8779 0.9786 1.7370 3.1210
2  Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
-0.02302 1.35400 2.10000 2.05500 2.61300 4.47800
3  Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
-0.3075 2.3820 3.0410 3.0650 3.7400 5.6130
```

Cette commande affiche le numéro de l'itération en cours (`cat(step)`), puis affiche les informations de base (`summary`) sur une distribution normale (`rnorm`) centrée sur `step`. Les boucles `for` peuvent contenir des instructions aussi longues que souhaité.

Une autre application des boucles `for` est de parcourir un objet. Par exemple, on peut souhaiter, pour chaque élément d'un objet, afficher sa valeur. R permet de réaliser ce genre d'opérations, avec la syntaxe suivante :

```
> vect = c('a', 'b', 'c', 'd')
> for (val in vect) cat(val)

abcd
```

Pour chaque élément du vecteur `vect`, que l'on nomme `val` pour pouvoir y accéder pendant les itérations, R va afficher la valeur que l'élément contient.

Les boucles `for` sont donc une façon explicite de faire la même chose que ce qui a été traité dans la séance précédente, avec un inconvénient majeur : elles sont extrêmement demandantes en temps de calcul. Dans la majorité des cas, il est préférable d'avoir recours autant que possible aux fonctions `*apply`, qui sont bien plus optimisées que des boucles.

2.2 Boucles de type *while*

Les boucles de type `while`, littéralement *pendant*, permettent de répéter une série d'instructions tant qu'une condition n'a pas été atteinte. Pour cette raison, il faut bien prendre en compte le fait que mal utilisées, ces boucles peuvent ne jamais stopper. Il faut donc faire particulièrement attention à la condition qui est évaluée à chaque itération.

Un exemple simple d'utilisation d'une boucle `while` est le calcul d'une factorielle. On veut calculer $n!$, ce qui se fait simplement en multipliant l'ensemble des $1 \leq k \leq n$.

```
> n = 5
> k = n
> while(k > 1){
  k = k - 1
  n = n*k
}
> print(n)

[1] 120
```

On remarquera que dans la parenthèse après `while` se trouve un test logique ; les tests sont abordés dans la partie suivante.

3 Tests

3.1 Expressions conditionnelles

```
> a = 4
> if (a == 4){
  print('yep')
}

[1] "yep"
```

3.2 Manipulation des valeurs booléennes

4 Fonctions

4.1 Généralités

L'utilisation des fonctions va permettre de gagner du temps dans la programmation. Comprendre le principe des fonctions dépasse de beaucoup le cadre de R, et mérite qu'on s'y arrête. Qu'est-ce qu'une fonction ? Une série d'instructions qui vont, à partir d'arguments, renvoyer un résultat. En quoi est-ce différent des scripts que nous avons utilisé jusqu'ici ? Écrire une fonction revient en quelque sorte à 'expliquer' le code une fois, et R se charge ensuite de redonner la bonne valeur aux arguments.

Le parallèle le plus évident est celui des fonctions mathématiques : si $f(x) = x^2$, on peut calculer $f(x)$ pour tout x , parce qu'on sait quoi faire. Ça devient donc très avantageux si on doit calculer $f(x)$ un grand nombre de fois. En écrivant uniquement des scripts, pour calculer la valeur de beaucoup de x^2 , on aurait écrit :

```
> 1^2
> 2^2
> 3^2
> 4^2
> 5^2
```

ou encore

```
> for(i in c(1:5)) i^2
```

Si il faut revenir sur ce code plus tard, et transformer tous les 2 en 3 , la première solution implique de tout corriger manuellement. En utilisant une fonction, la logique est différente :

```
> f = function(x) x^2
> f(2)
```

```
[1] 4
```

Peut importe le nombre de fois ou on devra effectuer l'opération contenue dans `f`, si on veut la modifier, elle sera toujours stockée au même endroit. Avec cet avantage en tête, quelques généralités sur les fonctions en R.

4.1.1 Tout est fonction

Dans la pratique, la majorité des instructions utilisées jusqu'à présent sont des fonctions. Par exemple, `print`, `read.table`, et `apply` sont des fonctions rendues disponibles par R.

4.1.2 Le scope

Les fonctions existent comme un espace «à part» dans R : ce qui se déroule dans une fonction, reste dans une fonction. Prennons le cas du code suivant :

```
> a = 2
> b = 3
> f = function(x){
  y = x+a
  z = y
  return(z)
}
> f(b)

[1] 5
```

La fonction `f` peut aller chercher la valeur de `a` dans l'environnement global, mais tout ce qui est défini au sein de `f` est inaccessible. D'ailleurs, tout ce qui est créé dans la fonction est détruit – retiré de la mémoire – une fois que la dernière instruction est exécutée. Voyez la section sur la fonction `return` pour plus de détails. Cette notion de quel objet est accessible est extrêmement importante à maîtriser.

Dans R, les objets existent dans deux «mondes», l'environnement global, et l'intérieur de chaque fonction. L'intérieur de chaque fonction peut avoir accès aux objets et aux variables de l'environnement global, même si cette pratique est à éviter pour différentes raisons (une variable globale peut être modifiée entre deux appels à la fonction, notamment). En revanche, l'environnement global n'a pas accès aux objets créés ou modifiés à l'intérieur d'une fonction. La communication avec les fonctions se fait ...

Le fait qu'on puisse passer des objets d'un environnement à l'autre peut entraîner un comportement assez surprenant. Dans l'exemple suivant :

```
> a = 2
> print(a)

[1] 2

> f = function(a)
{
  a = a+1
  return(a)
}
> print(f(a))

[1] 3
```

```
> print(a)
```

```
[1] 2
```

L'appel à la fonction `f` devrait modifier `a`, puisque la seule instruction de cette fonction est `a = a+1`. Or, quand on appelle cette fonction, puis qu'on affiche la valeur de `a`, elle n'a pas changé. Ce comportement vient du fait que l'objet `a` qui existe dans la fonction n'est pas celui qui existe dans l'environnement global. Par conséquent, le `a` de la fonction peut être modifié, sans que cela n'affecte le `a` de l'environnement de travail.

Cet exemple illustre aussi pourquoi le nom des variables est important. On sait que R est capable d'aller chercher, depuis une fonction, des variables de l'environnement global. Quelle version de `a` faut-il aller chercher ? Pour éviter les erreurs liées au fait que plusieurs variables aient le même nom, on essaie de donner un nom unique à toutes les variables. C'est sans doute plus long à écrire – même si cet argument n'est pas valable avec un éditeur qui auto-complète le code –, mais ça évite surtout les erreurs à l'exécution.

4.2 Déclarer une fonction

Comme illustré dans les exemples précédents, la déclaration d'une fonction se fait par

```
> nom_de_la_fonction = function(argument1, argument2)
{
    instructions
    return(sortie)
}
```

Les éléments les plus importants sont les arguments et l'instruction `return`.

4.2.1 La commande `return`

4.2.2 Arguments

Les arguments sont des variables

5 Mise en application

5.1 Test par permutation

Lorsque les données deviennent de la normalité, on peut préférer réaliser un test paramétrique avec des permutations plutôt qu'un test non paramétrique. La plupart des programmes de statistique n'offrent pas cette possibilité qui demande pourtant très peu d'efforts pour être implémentée dans R. Dans cette mise en application, on veut effectuer un test `t`, pour comparer deux distributions, disponibles dans un fichier `s4-data.txt`.

Le principe d'un test par permutations est simple. La première étape est d'effectuer le test sur l'échantillon non permuté, pour obtenir la valeur de la statistique (T). Dans le cas du test t , R propose la fonction `t.test`, et un rapide survol de `?t.test` vous donnera les arguments nécessaires et la manière de récupérer la statistique. Commencent ensuite les permutations à proprement parler. Pour un nombre n d'itérations choisies (en général 9999), on mélange l'ensemble des valeurs des deux distributions. On reconstruit ensuite, en tirant au hasard dans le *pool* de valeurs ainsi formées, deux distributions de taille égale. Cette étape peut, par exemple, prendre la forme d'une fonction `resample`, qui prendrait une `data.frame` avec deux colonnes (la valeur, et le groupe d'origine) en argument. R propose la fonction `sample`, qui permettra de mélanger la colonne correspondant au groupe (ce qui recréera automatiquement les deux distributions – économisons nous !). Une fois les deux distributions reconstruites, on calcule la nouvelle statistique T' . Si la valeur de T' est inférieure ou égale à la valeur de T , on incrémente une variable N de 1. Sinon, la valeur de N reste la même.

Le calcul de la *p-value* se fait de la manière suivante :

$$p = \frac{N}{n + 1} \quad (1)$$

À partir de ces informations, et des informations données dans l'introduction de cette séance, vous devez être en mesure de programmer sans difficultés une fonction `t.test.permut`, qui permet de réaliser un test t par permutations. En bonus, vous pouvez ajouter des arguments qui permettent de contrôler le nombre de permutations qui doivent être réalisées.

6 Solution des mises en application

6.1 Test par permutation

On commence par écrire une fonction `resample`, qui mélange l'attribution des valeurs à un des deux groupes.

```
> resample = function(df)
{
  df$group = sample(df$group)
  return(df)
}
```

Puis on écrit la fonction `t.test.permut`, qui effectue les permutations à proprement parler

```
> t.test.permut = function(df,n=9999)
{
  baseStat = t.test(value~group,df)$statistic
  N = 0
  for(repl in c(1:n))
    if(t.test(value~group,resample(df))$statistic<=baseStat)
      N = N + 1
  return(N/(n+1))
}
```

On peut générer un jeu de données de test :

```
> value = c(rnorm(100,mean=0),rnorm(100,mean=1))
> group = c(rep('a',100),rep('b',100))
> test_df = as.data.frame(cbind(value = value, group = group))
> test_df$value = as.numeric(as.vector(test_df$value))
```

puis vérifier que la *p-value* est inférieure à 0.05 :

```
> print(t.test.permut(test_df, n = 9))
```

```
[1] 0
```

Pour éviter les problèmes de lenteur des boucles `for`, on peut écrire la même fonction basée sur la fonction `replicate` :


```
> t.test.permut = function(df,n=9999)
{
  baseStat = t.test(value~group,df)$statistic
  return(sum(replicate(n,
    t.test(value~group,resample(df))$statistic<=baseStat)
  )/(n+1))
}
```

La différence sur 10000 répliqués est assez minime (3 secondes environ). Mais dans un contexte où il faut analyser plusieurs fois des jeux de données, ces petits écarts finissent par faire une différence importante.